



Universidad Nacional Autónoma de México

**Escuela Nacional de Estudios Superiores
Unidad Morelia**

Lic. en Tecnologías para la Información en Ciencias

Análisis del Dataset “Our World in Data CO2 and Greenhouse Gas
Emissions dataset”

Estadística Multivariada

Autor:

Mirell Araceli Romero Zerpa

Enero 2026

Abstract

En este proyecto se analizan patrones entre países a partir de variables socioeconómicas, demográficas y ambientales mediante técnicas de estadística multivariada y aprendizaje no supervisado. El conjunto de datos incluye variables como el PIB, población, emisiones de CO₂, gases de efecto invernadero, entre otros, los cuales presentan una alta correlación entre sí. Inicialmente, se ajusta un modelo de Regresión Lineal Múltiple (RLM) para evaluar la relación entre las variables predictoras y la variable respuesta, considerando la presencia de multicolinealidad. Posteriormente para reducir dimensionalidad y explorar la estructura principal de los datos se usó el Análisis de Componentes Principales (PCA) y a partir de las componentes obtenidas se emplearon los algoritmos DB-Scan y clustering jerárquico para identificar los grupos de países con características similares.

ÍNDICE

1. Presentación de los datos.....	4
1.1. Fuente de datos.....	4
1.2. Motivo de interés del estudio.....	4
2. Limpieza y preprocesamiento de los datos.....	5
2.1. Presentación de las variables.....	5
3. Análisis exploratorio de datos (EDA).....	6
4. Plots multivariados.....	12
4.1. Curvas de Andrews.....	12
4.2. Gráfico de coordenadas paralelas.....	13
5. Análisis de Componentes Principales (PCA).....	14
5.1. Imputación de valores nulos para variables predictoras.....	14
5.2. Estandarización de los datos.....	14
5.3. Varianza explicada e interpretación de los componentes principales.....	15
6. Regresión Lineal Múltiple (RLM).....	17
6.1. Definición del modelo.....	18
6.2. Ajuste del modelo.....	18
6.3. Evaluación del modelo.....	18
6.4. Interpretación de los coeficientes.....	19
6.5. Limitaciones del modelo.....	20
7. Clustering.....	21
7.1. Análisis exploratorio de la estructura de datos en el espacio PCA.....	21
7.2. Clustering Jerárquico.....	22
7.2.1. Selección del número óptimo de clusters.....	22
7.2.2. Descripción e Interpretación de los 6 Clusters.....	23
7.3. DB-Scan.....	26
7.3.1. Ajuste de parámetros.....	26
7.3.2. Resultados de clustering.....	27
7.4. Comparación de los métodos de clustering.....	29
8. Conclusiones.....	29
9. Bibliografía.....	30

1. Presentación de los datos

1.1. Fuente de datos

Los datos utilizados en este proyecto fueron obtenidos del conjunto de datos “Data on CO2 and Greenhouse Gas Emissions” publicado por Our World in Data (Ritchie et al., 2024). Contiene información a nivel país sobre emisiones de dióxido de carbono y gases de efecto invernadero, así como variables socioeconómicas y demográficas, a lo largo del tiempo (hasta 2024). Este conjunto de datos ha sido ampliamente utilizado en estudios sobre cambio climático y desarrollo global. Los datos ya fueron filtrados y preprocesados por los autores para asegurar consistencia entre países.

1.2. Motivo de interés del estudio

El estudio de las emisiones de carbono y su relación con las variables socioeconómicas y demográficas de un país es de relevancia en el contexto actual donde el cambio climático y el desarrollo sostenible son clave. Actualmente los países presentan bastantes diferencias en crecimiento económico, población y consumo energético, lo que se traduce en diferentes patrones de emisiones contaminantes. Un enfoque estadístico multivariado permite analizar múltiples factores influyentes en las emisiones, resultando en una interpretación más completa. Al utilizar modelos de regresión lineal múltiple podemos ver la relación entre las variables predictoras y las emisiones de CO2, mientras que el Análisis de Componentes Principales y los métodos de clustering permiten identificar la estructura de los datos y agrupar países con características similares. El análisis busca patrones globales y países que podrían ser considerados atípicos.

2. Limpieza y preprocesamiento de los datos

El dataset original consta de 79 variables totales relacionadas con emisiones de gases de efecto invernadero, características socioeconómicas, demográficas y energéticas para múltiples países y años. Sin embargo, al hacer una exploración inicial se vió que muchas variables tienen valores nulos, así como variables que no eran directamente relevantes para el objetivo de este análisis estadístico.

Primeramente se realizó un proceso de selección de variables, se evaluó el porcentaje de valores nulos y aquellas variables con un porcentaje muy alto de valores nulos. La información redundante o poco relevante para el estudio fueron excluidas del conjunto de datos. Posteriormente se seleccionó un subconjunto de variables que fueran teóricamente relevantes y con la mayor cantidad de valores completos, como resultado se conservaron variables demográficas, económicas y ambientales, así como emisiones por tipo de combustible.

Adicionalmente se definieron dos variables categóricas extras: `development_level` y `carbon_intensity`. La primera se derivó a partir del Producto Interno Bruto, para clasificar a los países según su nivel de desarrollo económico. La segunda se obtuvo a partir de la relación entre las emisiones de CO₂ y el PIB, permitiendo categorizar a los países de acuerdo con la intensidad de carbono de su actividad económica.

Finalmente se observó que los registros muy antiguos presentaban bastantes registros con valores nulos en variables importantes para el estudio; por lo tanto se decidió tomar en cuenta las mediciones a partir del año 1950.

2.1. Presentación de las variables

A continuación, se describen las variables utilizadas:

- **country**: nombre del país


- **iso_code**: código internacional de 3 letras que identifica a un país
- **year**: año correspondiente a la observación
- **population**: número total de habitantes de un país
- **gdp**: Producto Interno Bruto
- **co2**: cantidad total de dióxido de carbono emitido por un país
- **co2_per_capita**: emisiones de CO2 por persona
- **total_ghg**: emisiones totales de gases de efecto invernadero
- **cumulative_co2**: suma histórica de las emisiones de CO2 de un país
- **share_global_co2**: porcentaje de las emisiones globales de CO2 atribuidas a cada país
- **coal_co2**: emisiones de CO2 derivadas del uso de carbón
- **oil_co2**: emisiones de CO2 asociadas al consumo de petróleo
- **gas_co2**: emisiones de CO2 provenientes del uso de gas natural
- **cement_co2**: emisiones de CO2 generadas durante la producción de cemento
- **co2_per_gdp**: emisiones de CO2 por unidad de PIB
- **energy_per_capita**: cantidad promedio de energía consumida por habitante.
- **development_level**: construida a partir del PIB, que clasifica a los países en distintos niveles de desarrollo económico.
- **carbon_intensity**: derivada de CO2/PIB, clasifica a los países según el impacto ambiental de su actividad económica.

Las variables utilizadas en el análisis son predominantemente cuantitativas continuas, como las emisiones de CO2, PIB, población y consumo energético, las cuales permiten medir magnitudes económicas, demográficas y ambientales.

3. Análisis exploratorio de datos (EDA)

Se realizó un análisis exploratorio de datos para identificar tendencias y características relevantes, así mismo para detectar posibles relaciones entre variables, multicolinealidad y su comportamiento antes de aplicar técnicas de análisis multivariado. Se calcularon medidas descriptivas básicas como la media, moda, mediana, desviación estándar, valores mínimos y máximos; se encontró una alta variabilidad en la mayoría de las variables, especialmente en el tamaño

poblacional, PIB y emisiones de gases de efecto invernadero y CO₂. La diferencia entre la media y la mediana en varias variables nos dice que hay **asimetrías positivas**, es decir, pocos países tienen valores significativamente más altos que el resto. Este comportamiento es consistente con las economías y emisores a nivel mundial actualmente. La siguiente gráfica con escala logarítmica en el eje x, permite apreciar la distribución de las mediciones de emisiones de CO₂.




(gráfica de ejemplo de CO₂ en escala logarítmica)

En general se observó que las distribuciones no siguen una forma normal, sino que son asimétricas positivas. Los boxplots y scatterplots permitieron identificar outliers en variables relacionadas con emisiones totales y el consumo energético, estos valores corresponden principalmente a países con alto desarrollo industrial. La siguiente gráfica muestra la relación entre el PIB y las mediciones de CO₂.

Se observa una tendencia donde un mayor PIB se asocia con mayores emisiones de CO₂. Los países con un desarrollo alto tienden a concentrarse en la parte superior derecha del gráfico, indicando un PIB elevado y altas emisiones de CO₂, aunque algunos países de alto desarrollo muestran una disminución de CO₂,


mientras el PIB sigue alto. Los países de nivel medio tienen un rango de emisiones medio-alto y finalmente los países de nivel bajo tienen PIB y emisiones mucho más bajas, aunque unos pocos producen significativamente más emisiones en relación a su PIB. Muestra que los países más poblados contribuyen significativamente al PIB y a las emisiones.




Se puede comprobar que hay una relación entre el nivel de desarrollo y las emisiones de CO2 per cápita: a mayor nivel de desarrollo más emisiones de CO2. Los países con un nivel de desarrollo alto presentan las emisiones de CO2 per cápita más elevadas. Además se observan muchos outliers en cada nivel de desarrollo, indicando que algunos países de alto desarrollo tienen emisiones per cápita extremadamente altas. Los países con nivel de desarrollo medio tienen emisiones per cápita mucho menores que los de alto desarrollo y su dispersión es menor, aunque tiene bastantes outliers en la parte inferior indicando que una parte de la población de nivel medio emite menos emisiones que su media. Los países con nivel de desarrollo bajo tienen las emisiones de CO2 per cápita más bajas, esto

sugiere que, en promedio, los países menos desarrollados tienen una huella de carbono per cápita mucho menor.

Además se graficaron los 7 países con mayores emisiones a lo largo del tiempo. Estos fueron China, Estados Unidos, India, Rusia, Japón, Irán e Indonesia.







En la siguiente gráfica realizada con datos del 2022, se revela una correlación positiva entre las emisiones de CO₂ por carbón y por petróleo. Los países de bajo desarrollo se concentran en la zona de bajas emisiones de ambos combustibles, lo que coincide con su menor industrialización y consumo energético. Mientras que los países de desarrollo medio presentan una amplia dispersión, desde emisiones moderadas hasta una fuerte dependencia de uno o ambos combustibles, reflejando las economías en desarrollo. Los países de alto desarrollo muestran perfiles variados, aunque la mayoría se ubica en rangos de emisiones medias a altas, con diferentes preferencias por carbón, petróleo o ambos.

Los puntos más grandes y situados en la zona de mayores emisiones confirman que las emisiones totales de gases de efecto invernadero (GHG) están directamente vinculadas al uso intensivo de combustibles fósiles.

A partir de la matriz de correlaciones se detectó una alta multicolinealidad entre variables predictoras como (gdp, population, co2, total_ghg, coal_co2, oil_co2, gas_co2, cement_co2, co2_per_gdp, energy_per_capita, cumulative_co2, share_global_co2), como se ve en la matriz de correlación, donde tienen valores cercanos a 1 en la variable 'co2'. Por esto se utilizó PCA para capturar la estructura principal de los datos sin perder información relevante.



El análisis permitió identificar una alta dispersión y asimetría en las variables numéricas, además de outliers asociados a países con comportamientos extremos. Observamos una relación positiva entre variables ambientales y económicas, y una alta multicolinealidad entre variables predictoras. Estas observaciones nos permiten ver una estructura compleja y multicolineal en los datos.

4. Plots multivariados

4.1. Curvas de Andrews

Las curvas representan cada país como una función basada en todas sus variables. Países con perfiles similares tendrán curvas que se superponen o con patrones parecidos.


1. Estados Unidos (azul claro) y China (naranja)

Perfiles únicos y extremos: países con valores más altos en algunas variables, indicando fuerte variabilidad entre sus características, dominan variables con valores positivos. Tienen picos muy marcados y claramente son distintos al resto, es decir, tienen valores extremos en varias variables.

2. Grupos similares: India y Rusia muestran curvas muy similares, esto indica que tienen estructuras económicas/sociales parecidas, aunque sus perfiles son menos extremos comparados con EE.UU. Sugieren economías o emisiones altas pero con diferentes estructuras.


3. Sudáfrica, Brasil, Alemania y México (líneas verde claro y café)

Sudáfrica tiene un perfil ligeramente más alto que México, ambos muestran cierta similitud con el grupo principal. Son curvas más cercanas entre sí con menor variabilidad, estos parecen agrupamientos naturales y más densos.



4.2. Gráfico de coordenadas paralelas

El gráfico de coordenadas paralelas confirma la alta multicolinealidad observada en la matriz de correlación, especialmente entre `gdp`, `co2` y las emisiones por tipo de combustible, al mostrar líneas similares. Además, se identifican perfiles extremos para países como China y Estados Unidos, lo cual es consistente con lo observado en las curvas de Andrews, donde presentan comportamientos claramente diferenciados del resto.



5. Análisis de Componentes Principales (PCA)

El Análisis de Componentes Principales (PCA) se utilizó con el objetivo de reducir la dimensionalidad del conjunto de datos y capturar la mayor variabilidad del conjunto original en un número reducido de nuevas variables no correlacionadas. PCA va a facilitar la identificación de patrones y estructuras subyacentes. El análisis exploratorio inicial reveló una alta multicolinealidad entre las variables relacionadas con emisiones y factores socioeconómicos. Esto complica la interpretación de los datos y puede afectar el rendimiento de algoritmos de aprendizaje no supervisado, como clustering. Por estas razones, PCA se aplicó como un preprocesamiento previo a clustering para eliminar redundancia por multicolinealidad y para trabajar con un conjunto reducido de componentes pero que conservan la variabilidad original de los datos.

5.1. Imputación de valores nulos para variables predictoras

Antes de aplicar PCA, se realizó la **imputación de valores faltantes** en las variables numéricas; necesario debido a que PCA no admite registros con valores nulos.

Dado que las variables están correlacionadas, se optó por utilizar `IterativeImputer` de scikit-learn, el cual considera las relaciones y correlaciones entre múltiples variables, este método utiliza un modelo de regresión para predecir los valores faltantes, por defecto `BayesianRidge`. El algoritmo repite el proceso hasta que los valores convergen o se alcanza el número máximo de iteraciones. Se eligió este método porque nuestras variables están altamente correlacionadas, usando `IterativeImputer` podemos conservar la estructura multivariada.

5.2. Estandarización de los datos

Una vez imputados los valores faltantes, las variables numéricas fueron estandarizadas ya que PCA es sensible a la escala; asegura que todas contribuyan

equitativamente al análisis, independientemente de sus unidades de medida o escalas. Este paso es fundamental, ya que PCA se basa en la varianza de las variables.

5.3. Varianza explicada e interpretación de los componentes principales

A continuación se muestra la varianza explicada por cada componente resultante:

PC1:	Var = 0.593,	Acumulada = 0.593
PC2:	Var = 0.213,	Acumulada = 0.805
PC3:	Var = 0.105,	Acumulada = 0.911
PC4:	Var = 0.030,	Acumulada = 0.940
PC5:	Var = 0.023,	Acumulada = 0.964
PC6:	Var = 0.016,	Acumulada = 0.980
PC7:	Var = 0.007,	Acumulada = 0.987
PC8:	Var = 0.005,	Acumulada = 0.992
PC9:	Var = 0.003,	Acumulada = 0.995
PC10:	Var = 0.002,	Acumulada = 0.998
PC11:	Var = 0.001,	Acumulada = 0.999
PC12:	Var = 0.001,	Acumulada = 1.000
PC13:	Var = 0.000,	Acumulada = 1.000

	PC1	PC2	PC3
population	0.249	-0.058	0.424
gdp	0.342	-0.013	-0.037
co2	0.357	-0.013	0.039
co2_per_capita	0.027	0.595	0.041
total_ghg	0.351	-0.031	0.060
coal_co2	0.320	-0.031	0.340
oil_co2	0.325	0.013	-0.316
gas_co2	0.286	0.020	-0.470
cement_co2	0.270	-0.044	0.495
co2_per_gdp	0.013	0.559	0.090
energy_per_capita	0.034	0.570	0.002
cumulative_co2	0.319	0.009	-0.340
share_global_co2	0.322	0.002	-0.085

Vemos que **los primeros 3 componentes explican la mayor parte de la varianza total en un 91.1%**, es decir, gran parte de la información original puede representarse en un espacio de menor dimensión.

- **PC1: Escala de emisiones y actividad económica (59.3% de varianza)**

Este componente refleja el tamaño absoluto de la economía y su impacto climático.

Fuertemente asociado a variables de volumen total:

- Emisiones absolutas: co2 (0.357), total_ghg (0.351)
- Fuentes principales: oil_co2, coal_co2, gas_co2 (~0.30 cada una)
- Tamaño económico: gdp (0.342)
- Participación global: share_global_co2 (0.322)

PC1 ordena a los países según su contribución al cambio climático, distinguiendo entre grandes emisores globales y países con menor huella total, independientemente de su eficiencia o población.

- PC2: Intensidad de carbono y consumo energético per cápita (21.3% de varianza)

Este componente nos dice la intensidad de uso energético y la huella de carbono per cápita:

- Huella individual: `co2_per_capita` (0.595)
- Consumo energético per cápita: `energy_per_capita` (0.570)
- Intensidad de carbono en la economía: `co2_per_gdp` (0.559)

PC2 separa a los países según qué tan intensivos son en carbono y energía por persona y por unidad de PIB. Un valor alto indica economías con alto consumo energético individual o baja eficiencia económica.

PC3: Composición de la Matriz Energética (10.5% de varianza)

Este componente explica de qué fuentes proviene el CO₂:

- Fuentes industriales/mineras: `cement_co2` (0.495), `coal_co2` (0.340)
 - Variables demográficas: `population` (0.424)
 - Fuentes energéticas alternativas: `gas_co2` (-0.470), `oil_co2` (-0.316)
 - Historial de emisiones: `cumulative_co2` (-0.340)
- Valores positivos: Economías dependientes de carbón y producción de cemento, asociadas a industrialización o desarrollo basado en recursos.
- Valores negativos: Economías con mayor dependencia de gas y petróleo, que pueden reflejar patrones energéticos más diversificados o de mayor desarrollo.

El uso de PCA permitió reducir la dimensionalidad del conjunto de datos preservando la variabilidad de los datos.

6. Regresión Lineal Múltiple (RLM)

Se implementó un modelo de regresión lineal múltiple con el objetivo de explicar el comportamiento de las emisiones totales de dióxido de carbono (`co2`) a partir de variables directamente relacionadas con sus principales fuentes.

6.1. Definición del modelo

La variable dependiente seleccionada fue `co2`, mientras que las variables predictoras fueron `population`, `oil_co2`, `gas_co2`, `coal_co2` y `cement_co2`. Estas variables representan componentes fundamentales de las emisiones de CO2 y factores asociados a la demanda energética, por lo que son buenos estimadores de la variable objetivo.

El modelo de regresión lineal múltiple se plantea con el objetivo de evaluar la relación entre las emisiones totales de CO2 y sus principales fuentes y determinantes energéticos.

Hipótesis nula (H_0): Las variables predictoras (`population`, `oil_co2`, `gas_co2`, `coal_co2`, `cement_co2`) no tienen un efecto significativo sobre las emisiones totales de CO2.

Hipótesis alternativa (H_1): Al menos una de las variables predictoras tiene un efecto significativo sobre las emisiones totales de CO2.

Antes de la definición del modelo se eliminaron los registros faltantes de la variable `co2`, para la consistencia en la etapa de evaluación del modelo.

6.2. Ajuste del modelo

Los datos fueron divididos en conjuntos de 80% entrenamiento y 20% prueba, posteriormente fueron escaladas las variables numéricas. El modelo fue ajustado mediante regresión lineal utilizando mínimos cuadrados ordinarios.

6.3. Evaluación del modelo

Para evaluar su desempeño, se calcularon las siguientes métricas:

```
Mean Squared Error (MSE): 4758.34
R-squared (R2): 0.97
Mean Absolute Error (MAE): 27.34
```

El valor obtenido de R Squared = 0.97 es bastante alto, indica que el modelo explica el 97% de la variabilidad de las emisiones de CO2 basándose en las variables predictoras que utilizamos, es decir, refleja bien la estructura de los datos. Este resultado es coherente con las variables predictoras, ya que son componentes directos de las emisiones de CO2 total.

El Mean Absolute Error (MAE) nos dice (en las mismas unidades que CO2) cuánto se equivoca en promedio el modelo, en este caso un MAE de 27.34 quiere decir que en promedio el modelo se equivoca en unos 27.34 millones de toneladas de CO2. Recordemos que los rangos de emisiones van desde países que producen muy pocas toneladas de CO2 hasta países que producen miles de toneladas de CO2. El Mean Squared Error (MSE) es de 4758.34. En este caso considerando las otras dos métricas, un R2 alto y MAE relativamente bajo, sugiere que el modelo es preciso. Ambas métricas reflejan errores razonables considerando la amplia escala de los datos, que incluye países con emisiones muy bajas y otros con emisiones extremadamente altas.

6.4. Interpretación de los coeficientes

Los coeficientes del modelo se dan por la siguiente tabla:

	Feature	Coefficient
2	cement_co2	269.795397
1	oil_co2	255.536800
3	gas_co2	93.222446
0	population	30.126637

- cement_co2 (269.79): Es el predictor individual más fuerte, por cada unidad de aumento en las emisiones de la producción de cemento, las emisiones totales de CO2 aumentan en aproximadamente 270 unidades.
- oil_co2 (255.53): La siguiente más importante es el petróleo. Un incremento en las emisiones se traduce en +256 unidades.

- gas_co2 (93.22): El gas natural tiene una relación positiva significativa, aunque menor. Su coeficiente indica un aumento de 93 unidades por cada incremento en sus emisiones.
- population (30.13): Muestra un coeficiente positivo considerablemente menor que el de las fuentes energéticas. Si bien un mayor tamaño poblacional está asociado a mayores emisiones totales, su efecto directo es moderado en comparación con la actividad industrial del país.

Explican muy bien la variación en las emisiones totales de CO₂, reflejado en un rendimiento sobresaliente del modelo. A nivel país el total de emisiones está fundamentado principalmente por el consumo de combustibles fósiles y procesos industriales, más que por el tamaño de su población.

6.5. Limitaciones del modelo

Si bien el modelo presenta un excelente ajuste, la interpretación de sus coeficientes debe ser con cautela debido a la alta multicolinealidad entre las variables predictoras, previamente identificada en el análisis exploratorio. Esta multicolinealidad limita la interpretación individual de los coeficientes, es decir, impide atribuir efectos individuales precisos a cada variable; aunque no afecta significativamente la capacidad predictiva del modelo.

Por esta razón, la regresión lineal múltiple se utiliza principalmente como herramienta explicativa general de las emisiones totales de carbono y se complementa con análisis de componentes principales y el clustering.

Debido a la alta multicolinealidad entre las variables predictoras, el modelo de regresión se utiliza con fines explicativos globales, mientras que PCA se emplea como herramienta de reducción de dimensionalidad previa al análisis de clustering.

7. Clustering

Se realizó clustering para identificar grupos de países con características similares a partir de los componentes principales obtenidos mediante el Análisis de Componentes Principales (PCA). Usando los componentes principales podemos reducir la dimensionalidad del problema, eliminar la multicolinealidad y facilitar la detección de patrones en los datos. **El análisis se realizó exclusivamente sobre las observaciones correspondientes al año 2022**, esto debido a que la inclusión de datos desde 1950 introduciría variaciones estructurales asociadas a distintas etapas de desarrollo industrial y tecnológico, dificultando la identificación de patrones de una misma etapa; se priorizó un año para que se reflejen diferencias actuales entre países, no su evolución histórica.


7.1. Análisis exploratorio de la estructura de datos en el espacio PCA

Para explorar la estructura subyacente de los países en el espacio de componentes principales, se generó un gráfico utilizando las tres primeras componentes (PC1, PC2, PC3). Se ve una forma alargada y asimétrica a lo largo del eje PC1, concentraciones locales (más en el origen) y ramificaciones en PC2 y PC3. La mayoría de países se concentra cerca del origen pero se separa un número reducido de grandes emisores; confirmando la alta asimetría en la distribución global de emisiones. PC2 introduce una separación vertical, distinguiendo países por consumo energético; PC3 crea ramificaciones laterales, mostrando que países con niveles similares de PC1 y PC2 pueden tener perfiles de emisión diferentes según sus fuentes de energía.

La forma alargada y ramificada, junto con outliers indica que los datos no cumplen el supuesto de clusters esféricos y de tamaño similar, por lo que no sería adecuado usar K-Means. Como vimos que hay concentraciones locales, los puntos pueden definirse mejor por densidad usando DB-Scan que no espera una forma específica y puede manejar bien outliers. Además el clustering jerárquico tampoco requiere especificar previamente el número de clusters ni asume una forma específica, un

análisis mediante dendrogramas permite visualizar las **relaciones jerárquicas**, subgrupos y niveles de similitud entre los países.



Estructura 3D de PC1, PC2 y PC3



7.2. Clustering Jerárquico

7.2.1. Selección del número óptimo de clusters

La determinación del número óptimo de clusters (k) se basó en la evaluación conjunta de métricas el método del codo y la puntuación de Silhouette.




Aunque la gráfica nos dice que el codo está en k=4, se priorizó k=6 por las siguientes razones:

- k=4 generaba un cluster masivo (90% de las observaciones) y 3 clusters pequeños (China, India y Estados Unidos), con k=6 se produce una distribución más equilibrada, con un cluster grande pero los clusters más pequeños están mejor diferenciados; evita que se pierdan las diferencias por quedar en un grupo demasiado grande.
- El corte en k=4 forzaba similitudes artificiales, por la distancia a la que se unían las ramas. El corte en k=6 respeta uniones naturales, donde la distancia entre clusters es más homogénea.
- Con k=6 se distinguen perfiles más detallados que las categorías más genéricas (alto, bajo, muy alto).

Con k=6 el score de Silhouette no cae tan abruptamente considerando la diversidad de perfiles que representa usarla, es decir, aún con más clusters van a seguir estando en promedio bien clasificados.

7.2.2. Descripción e Interpretación de los 6 Clusters

A continuación se muestra una gráfica donde se aprecia la segmentación en clusters, proyectada en las primeras dos componentes principales; donde vemos una estructura clara y jerárquica.



Países en cada cluster:

Cluster 0 (34 países): Algeria, Argentina, Australia, Bangladesh, Brazil, Canada, Democratic Republic of Congo, Egypt, Ethiopia, France...

Cluster 1 (181 países): Afghanistan, Albania, Andorra, Angola, Anguilla, Antarctica, Antigua and Barbuda, Armenia, Aruba, Austria...

Cluster 2 (1 países): Russia

Cluster 3 (1 países): India

Cluster 4 (1 países): United States

Cluster 5 (1 países): China

- **Cluster 1 (color verde, 181 países): Bajas emisiones**

Estos son pequeños emisores y economías en desarrollo de bajo impacto. Estos tienen valores más bajos en todas las métricas absolutas (emisiones totales, PIB, población) y relativas bajas (emisiones per cápita, intensidad energética); indicando

baja intensidad de carbono individual e impacto climático total pequeño. Representa a la mayoría de los países. Incluye países como Afganistán, Albania, Angola, entre muchos otros.

- **Cluster 0 (color azul, 34 países): Emisiones medias**

Estas son economías medias con emisiones absolutas significativas pero no extremas. Presenta la menor intensidad carbono/PIB (co2_per_gdp), señal de mayor eficiencia económica en términos de emisiones. Incluye economías desarrolladas, grandes emergentes y exportadores de energía. Países como Argentina, Australia, Brasil, Canadá, Francia, Alemania, entre otros.

- **Cluster 2 (color morado, 1 país): Rusia**

"Gran Emisor con Alta Intensidad de petróleo y gas". Rusia forma un clúster individual debido a su perfil único, con alta intensidad carbono/PIB (co2_per_gdp) y emisiones per cápita elevadas y de GHG. Refleja una economía energética intensiva y exportadora, donde las emisiones están ligadas a la extracción y uso de hidrocarburos.

- **Cluster 3 (color rosa, 1 país): India**


India es una potencia emergente con base industrial en carbón, la cual se caracteriza por una población enorme y altas emisiones dominadas por el carbón. Tiene emisiones per cápita relativamente bajas pero con alta intensidad carbono/PIB (co2_per_gdp). Representa el crecimiento rápido basado en combustibles fósiles.

- **Cluster 4 (color verde claro, 1 país): Estados Unidos**

Tiene el PIB más alto y emisiones bastante elevadas en todas las categorías. Tiene las emisiones per cápita y el consumo de energía per cápita más altos, reflejando de un estilo de vida de alto consumo. A pesar de sus altas emisiones absolutas, su intensidad de carbono por PIB (co2_per_gdp) es relativamente bajo en comparación con otros grandes emisores, lo que sugiere una economía diversificada.

- **Cluster 5 (color turquesa, 1 país): China**

Es el mayor emisor global, dominado por carbón y cemento. Tiene valores máximos en casi todas las métricas absolutas y una dependencia masiva del carbón y cemento, así como un PIB y una población enorme. Aunque sus emisiones per cápita son altas, no son las más altas debido a su gran población, pero tiene una alta intensidad de `co2_per_gdp`.



7.3. DB-Scan

Con el fin de identificar agrupaciones naturales en los datos sin imponer supuestos sobre la forma o número de clusters, se aplicó DB-Scan sobre los componentes principales obtenidos a partir de las observaciones del año 2022. DB-Scan resulta adecuado debido a la estructura alargada, ramificada y con concentraciones locales de los datos, además de la presencia de países con comportamientos extremos, los cuales pueden ser tratados como ruido clusters aisladas.

7.3.1. Ajuste de parámetros

Las variables al igual que para los demás métodos fueron imputadas y estandarizadas previamente. Los parámetros `eps` (radio de vecindad) y `min_samples` (número mínimo de puntos para formar un cluster) son clave para el

desempeño, por lo que para optimizar la búsqueda se optó por utilizar Optuna, una biblioteca de Python de optimización de hiperparámetros.


Optuna exploró un espacio de búsqueda definido como:

```
eps = trial.suggest_float("eps", 0.5, 5.0)
min_samples = trial.suggest_int("min_samples", 1, 5)
```

Evaluó múltiples combinaciones posibles, para cada una se ajustó el modelo DB-Scan y se evaluó la calidad del cluster resultante mediante el score de Silhouette, se seleccionó la combinación de parámetros con mayor score.

7.3.2. Resultados de clustering

Con los parámetros obtenidos por Optuna, DB-Scan logró identificar un **cluster principal** que agrupa a la mayoría de los países. Así mismo detectó clústers de un solo país, correspondientes a grandes emisores globales como China, India, Rusia y Estados Unidos.



Clusters encontrados por DB-Scan (2022):

Cluster 0: 215 países

Cluster 1: 1 países

Cluster 2: 1 países

Cluster 3: 1 países

Cluster 4: 1 países

Cluster 0 (ejemplos): Afghanistan, Albania, Algeria, Andorra, Angola

Cluster 1 (ejemplos): China

Cluster 2 (ejemplos): India

Cluster 3 (ejemplos): Russia

Cluster 4 (ejemplos): United States

El clustering obtenido mediante DB-Scan revela una estructura muy desigual en los datos. Identificó un único cluster principal que agrupa a 215 países y clusters individuales de un solo país. Este resultado indica que la mayoría de los países presentan un perfil relativamente similar en el espacio de componentes principales, formando una región mucho más densa; por otro lado países como China, India, Rusia y Estados Unidos aparecen como clusters individuales debido a sus perfiles tan distintos, es decir, actúan como outliers separados de donde están la mayoría de los puntos.

Esta segmentación se nota en la visualización del espacio PCA, separándose del grupo en PC1 y en PC2 y PC3 tienen perfiles energéticos distintos. Esto nos dice que no existen suficientes países con perfiles similares a ellos para formar regiones densas y que sus características los convierten en outliers dentro del conjunto de datos.

Aunque este resultado es esperado ya que DB-Scan identifica regiones densas, evitando formar clusters donde no necesariamente los hay y separa ruido o outliers. En este caso buscó la región altamente densa donde se concentran la mayoría de los países, esta no tenía separaciones claras que permitieran dividirla en múltiples clusters independientes; por lo que se interpreta como un solo cluster.

7.4. Comparación de los métodos de clustering

Para evaluar los resultados y comprender mejor la estructura de los datos, se aplicaron dos enfoques de clustering: **clustering jerárquico** y **DBSCAN**, ambos sobre el espacio reducido definido por las componentes principales.

El clustering jerárquico permitió identificar subgrupos dentro del conjunto de países, confirmamos una estructura jerárquica definida con los 4 mayores emisores (China, India, Rusia y Estados Unidos) y dos clusters con emisores medio-altos y emisores bajos; ayudó fijar $k=6$ para que se vieran estas segmentaciones entre los países. Por su parte DB-Scan se centró en identificar una región de alta densidad y separar datos extremos sin imponer un número predeterminado de clusters; validó la estructura al encontrar un único cluster denso y 4 outliers. Mientras que el clustering jerárquico es útil para explorar subestructuras internas, DBSCAN resulta más adecuado para identificar outliers y patrones principales sin imponer una segmentación; la combinación proporcionó una visión complementaria de los datos.

8. Conclusiones

Se analizaron los perfiles de emisión de CO₂ por país mediante un enfoque multivariado. El análisis exploratorio reveló alta variabilidad, multicolinealidad y valores extremos.

La regresión múltiple lineal mostró buen poder predictivo sobre las emisiones totales de CO₂, pero con limitaciones interpretativas debido a correlaciones entre variables predictivas. El PCA redujo la dimensionalidad conservando la estructura original, revelando patrones complejos no esféricos. Mediante clustering jerárquico y DB-Scan optimizado por Optuna, se identificó que la mayoría de países comparten perfiles similares, mientras que unos pocos grandes emisores presentan comportamientos extremos. Se demostró la utilidad de combinar técnicas exploratorias, reducción de dimensionalidad y agrupación para comprender patrones globales de emisión.

9. Bibliografía

- Hannah Ritchie, Pablo Rosado, and Max Roser (2023) - “CO₂ and Greenhouse Gas Emissions” Published online at OurWorldinData.org. Retrieved from: 'https://ourworldindata.org/co2-and-greenhouse-gas-emissions' [Online Resource]
- *IterativeImputer*. (s. f.). Scikit-learn. <https://scikit-learn.org/stable/modules/generated/sklearn.impute.IterativeImputer.html>
- *Optuna - A hyperparameter optimization framework*. (n.d.). Optuna. <https://optuna.org/>
- Sanchez, T. a. a. M. G. (n.d.). *3.8 PCA and Clustering | Principal Component Analysis for Data Science (pca4ds)*. <https://pca4ds.github.io/pca-and-clustering.html>
- *RPubs - Clustering on PCA results*. (n.d.). <https://rpubs.com/Bury/ClusteringOnPcaResults>